

SECRETARIA DE ESTADO DE CIÊNCIA, TECNOLOGIA E INOVAÇÃO
Programa SCTEC - Governo de Santa Catarina - parceria com o SENAI/SC –
Carreira Tech

Trilha Inteligência Artificial – Desafio Prático

1. OBJETIVO

Realizar uma Análise Exploratória de Dados (AED) no *dataset Uber Data Analytics Dashboard* para compreender o comportamento operacional e financeiro do serviço de corridas, identificando padrões de utilização, fatores que influenciam o valor das corridas e oportunidades para otimização do serviço.

2. ETAPAS

Para cumprimento do objetivo proposto, o trabalho foi executado respeitando-se as etapas a seguir: configuração inicial e importação de dados, compreensão do dataset, limpeza e tratamento e quais análises foram realizadas.

2.1. Configuração inicial e importação do dataset

Previamente à importação do dataset, foi preparado um ambiente virtual isolado para este projeto com a instalação das bibliotecas necessárias: pandas, numpy, matplotlib e seaborn, conforme detalhado no anexo “requirements.txt”.

Por fim, foi realizada a importação do *dataset “Uber Data Analytics Dashboard”*, mantendo o mesmo dentro da pasta onde está o arquivo .py, de modo a viabilizar portabilidade do código em uma pasta chamada “data”, evitando utilizar caminhos relativos dentro do código e problemas ao abri-lo em outra máquina.

2.2. Compreensão do dataset

Informações importantes sobre o *dataset*:

- ✓ Possui 21 colunas e 150.000 linhas de dados;
- ✓ Tipos de dados por coluna;
- ✓ Contagem de valores não nulos por coluna;

- ✓ Contagem de valores nulos e respectivas taxas;
- ✓ Estatísticas descritivas para colunas numéricas: média, mediana, desvio padrão, valor mínimo, valor máximo, distribuição por quartis;
- ✓ Estatísticas descritivas para colunas categóricas: contagem, número de valores únicos, valor mais frequente e frequência do valor mais frequente.

2.3. Limpeza e tratamento do dataset

De modo geral, optou-se pela manutenção de dados para análises subsequentes tanto para colunas com dados nulos, quanto *outliers*, não foram detectados valores duplicados. A seguir, detalhamento no tratamento aplicados:

Tipo de tratamento	O quê?	Onde?	Como?
Valores nulos	Colunas > que 50% de valores nulos	Cancelled Rides by Customer, Reason for cancelling by Customer, Cancelled Rides by Driver, Driver Cancellation Reason, Incomplete Rides, Incomplete Rides Reason	Considerado remover uma vez que interessa as corridas efetivamente completadas e a alta falta de dados, girando de 82% a 94%.
	Colunas == 38% nulos	Driver Ratings, Customer Rating	Manter colunas e preencher com mediana.
	Colunas == 32% nulos	Avg CTAT, Booking Value, Ride Distance, Payment Method	Manter colunas e preencher com mediana.
	Colunas == 7% nulos	Avg VTAT	Manter colunas e preencher com mediana.
Outliers	0,40%	Avg VTAT	Ajuste de valores extremos: não há valor negativo para tempo de espera do passageiro, então ajustados negativos para "0".
	1,50%	Avg CTAT	Viagens > de 2hs são raras, então limitou-se a tempo de viagem para 120 minutos.
	11,60%	Booking Value	Limitado valor de corrida até R\$ 1.000,00 porque quantidade de corridas acima desse valor são raros.
	34,10%	Driver Ratings	Considerado normal muitas avaliações em 5, sem necessidade de alterar.
	7%	Customer Rating	Mesma lógica aplicada para Driver Ratings.

Ao final do tratamento, mantiveram-se 150.000 registros, nenhum nulo e todos os *outliers* tratados de acordo os limites especificados na tabela acima.

2.4. Análises realizadas

- ✓ **Cancelamentos** – analisada distribuição de corridas completadas, canceladas pelo condutor, canceladas pelo passageiro, motorista não encontrado e não completadas;
- ✓ **Tipo de veículos** - Auto, Go Mini, Go Sedan, Bike, Premier Sedan, eBike, Uber XL;
- ✓ **Temporal**: distribuição de quantidades de corridas ao longo do dia desde 00:00 às 23:59hs, por semana e por mês;
- ✓ **Valor e distância** - concentração de ocorrências até R\$ 500,00 e até 50km;
- ✓ **Avaliações**: maior concentração de avaliações de motoristas está entre 4,25 e 4,50 quanto a passageiros está em 4,50 a 4,75, ligeiramente acima;
- ✓ **Métodos de pagamentos** - UPI, cartão de débito, cartão de crédito, dinheiro, carteira UBER. O ticket médio por tipo de pagamento não é semelhante entre os diferentes métodos de pagamento;
- ✓ **Tempos de viagem** - tempo médio de espera e tempo médio de viagem.

3. CONCLUSÕES E INSIGHTS

A partir das análises feitas na etapa anterior, foi possível chegar às seguintes conclusões:

- 3.1. Volume de dados: 150.000 corridas registradas.
- 3.2. Taxa de conclusão: 62.0% das corridas são completadas.
- 3.3. Taxa de cancelamento: 25.0%.
- 3.4. Veículo mais utilizado: Auto¹ (37.419 corridas).
- 3.5. Veículo com maior valor médio: Go Sedan² (R\$ 454.65).
- 3.6. Padrões temporais:
Horário de pico: 18h com 12.397 corridas.
- 3.7. Dia com mais corridas: Segunda.
- 3.8. Método de pagamento mais utilizado: UPI³ (93.909 corridas).
- 3.9. Avaliações:
 - Média das avaliações dos motoristas: 4.26;
 - Média das avaliações dos clientes: 4.44.

4. ANEXOS

- ✓ Pasta “data” que contém “ncr Ride Bookings.csv” e “ncr Ride Bookings Tratado.csv”;

¹ Triciclos motorizados (popularmente conhecidos como tuque-tuque).

² Opção econômica, mas com maior porta-malas.

³ UPI significa **Unified Payments Interface** (Interface de Pagamentos Unificados). É um sistema de pagamento digital em tempo real que permite transferências bancárias instantâneas via celular, agindo como o "Pix da Índia".

- ✓ desafio_sctec_ia.py;
- ✓ Documentacao_SCTEC_ia;
- ✓ requirements.txt.